

Walmart 周销售额影响因素分析与预测

技术报告

数据分析与建模实践

2026 年 9 月 20 日

摘要

本报告使用 Walmart 45 家门店、143 周（2010-02-05 至 2012-10-26，共 6435 条）的周销售额数据，回答哪些因素影响销售额，以及如何对未来周销售额做出稳健预测。分析上先做结构化审计与去混淆清洗，再通过固定效应回归、SHAP 与滞后/滚动特征解释影响因素；预测上采用 DTW 动态时间规整 + 层次聚类对门店分组，并为每个聚类分别训练一个 XGBoost（记为 **B_cluster**），与全局池化和单店建模作对照。所有模型在扩展窗口滚动交叉验证下评估，主指标为 Walmart 官方加权绝对误差 WMAE（节假日周权重为 5）。**B_cluster** 表现最好：滚动 CV 汇总的 WMAE 为 58,500、WAPE 为 0.0472、 R^2 为 0.9812；末段留出（最后 13 周）的 WMAE 为 35,977、WAPE 为 0.0329、 R^2 为 0.9913，最差门店误差也低于 7%。此外，销售额主要由门店自身历史动量与规模决定，宏观变量影响显著但效应量偏小，模型主要短板在节假日周。

1 问题重述

给定 Walmart 45 家门店的周度销售记录，需要回答两个问题：一是哪些变量影响周销售额，影响的方向与强弱如何；二是如何对未来周销售额做出准确且稳健的预测。约束是只能使用时间上过去的信息，避免未来信息泄漏，同时评估口径要贴近业务。数据时间跨度约 2.7 年，门店数远多于时间点数，属于典型的面板（panel）结构。

2 数据清洗与处理

2.1 数据集字段说明

数据共 8 个字段，均为门店-周粒度，各字段的含义与在建模中的角色见表 1。

表 1: 数据集字段说明

字段	类型	含义	建模角色
Store	整数	门店编号 (1-45)	分组、固定效应
Date	日期	周度日期 (每周五)	时间索引, 派生时间特征
Weekly_Sales	浮点	该店该周销售额	目标变量
Holiday_Flag	0/1	是否节假日周	特征, 并用于 WMAE 加权
Temperature	浮点	当周平均气温 (华氏度)	外生特征
Fuel_Price	浮点	当周油价	外生特征
CPI	浮点	消费者物价指数	外生特征
Unemployment	浮点	失业率	外生特征

需要说明的是, 数据集已经聚合到门店-周层级, 不含部门明细, 也不含门店的地理位置、商圈、人口密度等静态属性。这些未观测信息也是采用聚类分组的动机。

2.2 结构审计

对原始数据做完整性审计, 结果为结构零损坏: 无缺失值、无重复行、日期全部合法, 主键 (门店, 日期) 唯一且构成完整的 45×143 面板。因此不需要删除或插补任何行。

2.3 极值、分段与损坏程度

面板数据的方差主要来自门店之间 (CPI 为 99%、Weekly_Sales 为 94%、Unemployment 为 91%), 若直接对合并数据使用 IQR 判据, 会把门店规模差异误判为异常。改用门店内 (within-store) 判据后, 各字段的异常情况见表 2。

表 2: 极值与损坏程度 (门店内判据)

字段	门店内离群	门店内极端	等级	处理策略
Weekly_Sales	300 (4.66%)	154 (2.39%)	L2	保留, log1p + 单独评估节假日
Unemployment	32 (0.50%)	0	L1	差分/去趋势, 不删
CPI	0	0	L1	差分/去趋势
Temperature	0	0	L0	保留, 分箱
Fuel_Price	0	0	L0	保留

Weekly_Sales 的极端点中约 33.8% 落在节假日周, 属于真实的业务尖峰, 予以保留。因此清洗的重点是去除混淆, 即消解门店效应与时间趋势, 而不是纠错。

2.4 数据预处理方式

- 日期解析: 按 %d-%m-%Y 解析为日期型, 并派生年、月、周号、季度等时间特征;
- 目标变换: 对 Weekly_Sales 做 $\log(1 + y)$ 变换以削弱右偏, 评价前用 Duan smearing 做偏差校正还原;

- 平稳化：对 CPI、Unemployment 做差分或去趋势，缓解非平稳与共线；
- 固定效应：以门店哑变量或组内去均值吸收门店固有水平差异；
- 历史特征：在门店内构造滞后与滚动特征，严格只使用当前期之前的值；
- 缺失处理：滞后特征在序列早期会产生缺失，按折用训练行中位数填充，避免跨越时间填充；
- 缩尾：仅在训练折内对目标做缩尾，不触及验证与测试集；
- 切分：所有评估均按时间切分，禁止随机打乱。




图 1: 主要变量间的 Pearson 相关热力图

3 模型建立

3.1 特征与目标变量选择

目标变量为 `Weekly_Sales`。选择它是因为它直接刻画门店经营结果，且做 $\log(1+y)$ 变换后分布更接近对称，便于线性与树模型学习。

特征分为三类。第一类是外生变量：`Temperature`、`Fuel_Price`、`CPI`、`Unemployment` 与 `Holiday_Flag`，用于刻画外部环境与节假日效应。第二类是时间特征：月、周号、季度，用于捕捉年度季节性。第三类是历史特征：门店内的一周、两周、四周、五十二周滞后，以及 4、8、13 周的滚动均值与标准差，用于刻画销售动量与近期波动。

`Store` 不作为普通数值特征直接入模，避免把门店编号误当作有序变量；它通过门店哑变量或分组来使用。`Date` 不直接入模，而是派生为时间特征。含门店哑变量的设计矩阵维度为 63。

3.2 模型选型原则

按照从简到繁的路线推进：季节朴素、门店均值、Ridge，再到梯度提升（LightGBM 与 XGBoost）。每增加一层复杂度，都必须在滚动 CV 上证明有显著改善，否则回退到更简单的模型。

3.3 聚类的作用

数据集中并不包含门店的地理位置、商圈、人口密度和居民收入等信息，而这些因素会明显影响销售额。它们虽然无法直接观测，却会反映在门店销售序列的形态上，例如规模水位、季节性幅度、节假日响应和波动模式。DTW（动态时间规整）允许时间轴伸缩对齐，比欧氏距离更能刻画节奏相似的门店，因此用它度量门店序列之间的相似度，再用层次聚类把门店分成若干同类群。这样做相当于用可观测的销售形态，间接替代不可观测的地理与人口等隐藏变量，在共享样本量与保留门店差异之间取得折中。

- 全局池化只训练一个模型，共享充分但忽略门店差异；
- 单店建模训练 45 个模型，保留差异但每店仅 143 个样本，容易过拟合；
- 簇级建模训练 5 个模型，是两者的折中，也是最终采用的最优方案。

3.4 聚类与建模细节

对门店和周组成的 $\log(1 + \text{销售额})$ 序列计算 45×45 的 DTW 距离矩阵，用平均连接（average linkage）做层次聚类，并以轮廓系数自动确定簇数，同时约束每簇不少于 5 家店，以排除离群店单独成簇的退化解。最终得到 $K = 5$ ，簇规模为 $[7, 11, 11, 9, 7]$ ，各簇与门店规模大致对应。每个簇内汇总各门店的样本，训练一个浅层 XGBoost。




图 2：左：按簇排序的门店 DTW 距离矩阵；右：轮廓系数随簇数的变化（最优 $K = 5$ ）

3.5 模型训练过程

训练的主要设置与流程如下。基学习器采用浅层 XGBoost，超参数见表 3，以限制模型容量、降低小样本下的过拟合风险。

表 3: XGBoost 超参数

参数	取值
n_estimators	300
learning_rate	0.05
max_depth	3
min_child_weight	5
subsample	0.8
colsample_bytree	0.8
reg_lambda	1.0

- 目标: $\log(1 + y)$; 预测后按 Duan smearing 因子还原, $\hat{y} = \exp(\hat{z}) \cdot \overline{\exp(e)} - 1$;
- 分组训练: 对 5 个簇分别拟合一个模型, 簇内门店样本合并使用, 但不含门店哑变量;
- 交叉验证: 扩展窗口滚动原点 CV, 共 5 折, 每折验证 13 周, 训练集只含验证期之前的数据;
- 特征缺失: 滞后特征在每折内用训练行中位数填充;
- 复现性: 随机种子固定为 42, 线程数设为 1;
- 预测: 验证集门店按其所属簇调用对应模型, 还原到原尺度后计算指标。

3.6 验证策略

采用扩展窗口的滚动原点交叉验证, 训练集只包含验证期之前的数据, 验证段随时间前推; 另外保留最后 13 周作末段留出终验。这样既避免了随机切分带来的未来信息泄漏, 也能观察模型在不同时间段的稳定性。

4 模型评价指标

评价在原始金额尺度上进行, 主要指标及其含义见表 4。其中 WMAE 为 Walmart 官方口径, 节假日权重为 5, 是本次的主指标。MASE 以季节朴素 (去年同周) 为基准, 取值小于 1 才说明优于该朴素方法。

表 4: 模型评价指标

指标	公式	值偏向
MAE	$\frac{1}{n} \sum y - \hat{y} $	越小越好
RMSE	$\sqrt{\frac{1}{n} \sum (y - \hat{y})^2}$	越小越好
WMAE	$\frac{\sum w_i y_i - \hat{y}_i }{\sum w_i}$, 节假日 $w = 5$	越小越好
WAPE	$\frac{\sum y - \hat{y} }{\sum y }$	越小越好
R^2	$1 - \frac{\sum (y - \hat{y})^2}{\sum (y - \bar{y})^2}$	越大越好
MASE	$\frac{\text{MAE}}{\text{MAE}_{\text{季节朴素}}}$	越小越好 (< 1 优于朴素)

5 分析模块与模型对比

整个分析分为四个模块。数据探索模块考察变量分布与相关结构。训练模块覆盖基线模型、DTW 聚类与三层建模，并输出损失曲线。测试评估模块完成末段留出、分年份/节假日/温度/门店的分层评估，以及残差诊断和泄漏审计。模型解释模块使用固定效应回归（门店与年份固定效应、HC1 稳健标准误）、VIF 共线性诊断、SHAP 与线性特征权重。

各模型在滚动 CV 下的总体指标对比如表 5。

表 5: 滚动 CV 总体指标对比（按 WMAE 升序）

模型 / 层级	WMAE	WAPE	RMSE	R^2
B_cluster (DTW+ 聚类 +XGBoost)	58,500	0.0472	77,775	0.9812
A_global (全局池化 +XGBoost)	61,087	0.0506	81,769	0.9792
LightGBM (全局)	62,580	0.0511	82,621	0.9788
季节朴素	62,770	0.0561	87,540	0.9762
C_store (单店 XGBoost)	68,138	0.0566	103,904	0.9665
Ridge (全局)	100,321	0.0719	133,172	0.9449
Ridge (单店)	103,936	0.0818	153,409	0.9269
门店均值	106,034	0.0885	167,017	0.9134




图 3: 模型预测准确率排名（横向柱状图，按 WMAE 排序）

梯度提升整体优于线性模型。季节朴素的 R^2 已达 0.976，说明门店规模与年度季节性主导了销售额；单店建模因样本过少而过拟合，整体表现最差。

6 可视化结果分析

变量分布图显示 `Weekly_Sales` 明显右偏，取 $\log(1 + y)$ 后接近对称，说明对数变换是合适的；气温呈双峰，反映南北门店的气候差异。

相关热力图显示，各外生变量与销售额的线性相关都很弱，说明关系以非线性为主，这也是引入树模型和滞后特征的原因；油价与时间相关性较高，提示其带有明显的时间趋势。

DTW 距离矩阵在按簇排序后呈现清晰的分块结构，轮廓系数在 $K = 5$ 处最高，说明门店可以稳定地分为五类，且与门店规模层次对应。

损失曲线中训练与验证 RMSE 同步下降并很快趋稳，两者间距不大，未出现明显过拟合。预测值与真实值的散点基本贴近对角线，时间序列图也吻合良好。残差近似零均值且左右对称，异方差主要来自门店之间量级的差异。

SHAP 与标准化线性权重一致显示：上周销售额 (`lag1`) 的影响远大于其他特征，其次是 `lag2` 与滚动均值，宏观变量贡献很小。模型排名图则直观给出各模型的优劣次序。




图 4：左：XGBoost 训练与验证损失曲线；右：标准化线性模型特征权重

7 最优结果

最优模型为 `B_cluster` (DTW + 层次聚类 + XGBoost)，结果见表 6。

表 6：最优模型结果

场景	WMAE	WAPE	MAE	RMSE	R^2	MASE
滚动 CV (汇总)	58,500	0.0472	—	77,775	0.9812	—
末段留出 (13 周)	35,977	0.0329	33,842	49,144	0.9913	0.6417

门店级 WAPE 的中位数为 0.0317, P90 为 0.0476, 最差门店为 0.0692, 均低于 7%。模型不仅在整体上表现良好, 在最差门店上也保持稳健, 这是簇级建模相对全局模型的主要优势。




图 5: 上: 末段留出的预测值与真实值对比; 下: 残差分布

7.1 影响因素

固定效应回归给出的 log 空间系数 (可近似看作弹性) 为: 节假日 +5.1%、失业率 -3.9% 每百分点、油价 +3.4%、CPI +1.3%、气温 -0.08% 每华氏度; 各项 VIF 均小于 1.25, 不存在多重共线性。SHAP 显示预测上真正起主导作用的是门店自身历史, lag1 (上周销售额) 远高于 lag2、滚动均值、周号与 lag52, 宏观变量的贡献很小, 各特征的影响程度见附录表 7。两种证据相互印证: 节假日对销售额有正向作用, 宏观变量统计显著但效应量小, 销售额首要由自身动量、门店规模与年度季节性决定。

8 模型优点与不足

模型的主要优点有四点。其一, 整个评估建立在无泄漏的滚动 CV 之上, 训练只使用过去信息, 再配合末段留出, 结论较为可信。其二, 簇级建模在共享样本量与保留门店差异之间取得平衡, 不仅整体最优, 最差门店的表现也最好。其三, 通过对数变换与门店固定效应, 较好地处理了目标的右偏与门店异质。其四, 解释与预测并重, 固定效应回归与 SHAP 相互印证, 使影响因素的方向与强弱都有依据。

不足也有几点。一是节假日周仍是短板，在这类周上模型甚至不如季节朴素，说明节假日尖峰还没有被充分刻画。二是聚类基于整段序列进行。三是 DTW 的距离矩阵复杂度为 $O(N^2)$ ，门店数量增大时计算开销明显。四是数据集缺少门店静态属性，聚类只是间接替代。五是当前验证为提前一周的单步预测。六是单店样本量有限，未采用完全个性化建模，簇级方案是在此约束下的折中。

9 总结

数据在结构上没有损坏，但统计上高度异质，清洗的核心是去混淆而非纠错。建模上采用 DTW + 层次聚类 + XGBoost 的三层方案，用销售形态间接替代不可观测的地理与人口等信息。最优模型 `B_cluster` 在滚动 CV 和末段留出上均表现最好，最差门店的结果也最稳。影响因素方面，销售额主要由自身历史动量、门店规模与年度季节性决定，宏观变量显著但效应量小。当前的主要短板在节假日周。

A 详细图表




图 6: XGBoost 特征 SHAP 蜂群图 (特征集与最优模型一致, 不含门店哑变量)




图 7: 主要变量的分布

图 6 的纵轴列出了全部参与建模的特征。除 `Holiday_Flag`、`Fuel_Price`、`Temperature` 等原始字段外，其余都是本项目新增的构造特征。`lag` 类表示门店自身的历史销售额，即前若干周的 $\log(1 + y)$ ；`roll_mean` 与 `roll_std` 分别表示前若干周的滚动均值与滚动标准差，用于刻画近期水平与波动；`month`、`week`、`quarter` 由日期派生，用于捕捉年度季节性。所有 `lag` 与 `roll` 特征都在门店内构造，且只使用当前期之前的值。各特征对销售额预测的影响程度见表 7。

表 7: 各特征对销售额预测的影响程度（平均绝对 SHAP 值）

特征	含义	平均绝对 SHAP	影响程度
<code>lag1</code>	前 1 周销售额	0.3161	最高
<code>lag2</code>	前 2 周销售额	0.1077	高
<code>roll_mean4</code>	前 4 周滚动均值	0.0404	中
<code>lag4</code>	前 4 周销售额	0.0344	中
<code>week</code>	周号	0.0216	中
<code>lag52</code>	前 52 周（去年同周）销售额	0.0115	低
<code>roll_std4</code>	前 4 周滚动标准差	0.0104	低
<code>month</code>	月份	0.0078	低
<code>Holiday_Flag</code>	是否节假日	0.0046	低
<code>roll_std8</code>	前 8 周滚动标准差	0.0034	低
<code>roll_mean8</code>	前 8 周滚动均值	0.0033	低
<code>Fuel_Price</code>	油价	0.0024	低
<code>roll_mean13</code>	前 13 周滚动均值	0.0023	低
<code>roll_std13</code>	前 13 周滚动标准差	0.0019	低
<code>Temperature</code>	气温	0.0015	低

可以看到，对销售额影响最大的是门店自身的近期历史（`lag1`、`lag2`、`roll_mean4`），其次是与年度季节性有关的 `week`、`lag52` 和 `month`；节假日、油价、气温等原始外生变量的影响相对较小。

这与正文固定效应回归的结论一致：节假日、失业率等原始字段在统计上显著，但效应量不大。

B 术语表

表 8: 术语与缩写说明

术语 / 缩写	全称	说明
MAE	Mean Absolute Error	平均绝对误差。
RMSE	Root Mean Squared Error	均方根误差。
WMAE	Weighted Mean Absolute Error	加权平均绝对误差，节假日周权重为 5，本次主指标。
WAPE	Weighted Absolute Percentage Error	整体绝对百分比误差， $\sum y - \hat{y} / \sum y $ 。
R^2	Coefficient of Determination	决定系数， $1 - SS_{res}/SS_{tot}$ ，越大越好。
MASE	Mean Absolute Scaled Error	相对季节朴素的缩放误差，小于 1 表示优于季节朴素。
DTW	Dynamic Time Warping	动态时间规整，允许时间轴伸缩对齐的序列距离。
层次聚类	Hierarchical Clustering	逐步合并样本的聚类方法，本次采用平均连接。
轮廓系数	Silhouette Coefficient	聚类质量指标，取值 $[-1, 1]$ ，越大表示分簇越清晰。
XGBoost	Extreme Gradient Boosting	带正则化的梯度提升树算法。
LightGBM	Light Gradient Boosting Machine	采用直方图分箱与叶子优先生长的高效梯度提升树实现。
SHAP	SHapley Additive exPlanations	基于博弈论的特征贡献分解，用于解释模型。
VIF	Variance Inflation Factor	方差膨胀因子，用于诊断多重共线性。
HC1	Heteroskedasticity-Consistent 1	异方差稳健标准误，用于回归系数的推断。
固定效应	Fixed Effects	为每个个体设置专属截距，吸收其固有差异，此处用于门店。
池化	Pooling	将多个主体的样本合并后训练同一个模型。
滚动原点 CV	Rolling-origin Cross Validation	训练集只含过去信息、验证段随时间前推的交叉验证。
扩展窗口	Expanding Window	训练集随时间递增的窗口设置。
面板数据	Panel Data	多个主体在多个时期上的二维数据。
Duan smearing	Duan Smearing Estimator	对数模型还原到原尺度时的偏差校正方法。
log1p	$\log(1 + y)$	对右偏目标做对数变换，缓解长尾。
缩尾	Winsorization	将极端值截断到分位点，降低离群点影响。
季节朴素	Seasonal Naive	用去年同周的销售额作为预测，作为强基线。